

Аналитический отчёт по курсовой работе

«Предсказание эффективности химических соединений»

Данная курсовая работа посвящена задаче хемоинформатики: прогнозированию эффективности и безопасности химических соединений против вируса гриппа на основе их молекулярных параметров. В распоряжении имелся набор данных из 1000 соединений с указанными целевыми метриками: IC_{50} (концентрация полумаксимального ингибирования), CC_{50} (цитотоксичность) и SI (индекс селективности).

Цель работы — провести разведочный анализ данных EDA, построить ряд предсказательных моделей как регрессии, так и классификации и определить оптимальные алгоритмы для поиска эффективных лекарственных препаратов.

EDA и предобработка

Для обеспечения высокого качества предсказаний моделей был проведен тщательный анализ и очистка данных, а именно очистка шума и дубликатов, удален технический столбец Unnamed: 0, дублирующий индексы. Выявлены и удалены 32 полностью дублирующийся строки, что могло привести к data leakage при обучении. Удаление пропусков, в очищенном датасете было обнаружено 36 пропущенных значений (NaN). Ввиду их крайне малого количества, пропуски были заполнены медианными значениями соответствующих признаков, чтобы сохранить размер выборки без искажения статистики. Удаление признаков с нулевой дисперсией, выявлено и удалено 18 константных признаков, например, счетчики редких молекулярных фрагментов, состоящие только из нулей, не несущих предиктивной ценности. Трансформация целевых переменных, так как визуальный анализ показал, что таргеты IC_{50} , CC_{50} , SI имеют ярко выраженное правостороннее скошенное распределение. Для стабилизации дисперсии применено логарифмирование (np.log1p). Например, для IC_{50} это позволило снизить коэффициент асимметрии с 3.76 до почти идеального -0.02. Данные представлены на рисунках 1 и 2.




Рисунок 1 – Данные до логарифмирования



Рисунок 2 – Данные после логарифмирования

Устранение мультиколлинеарности, рассчитана матрица корреляций Пирсона. Удалено 47 признаков, имеющих взаимную корреляцию выше 0.90, что важно для устойчивости линейных моделей. Защита от утечки данных, а именно подтверждено, что математическое правило датасета:

$$SI = CC_{50} / IC_{50}$$

соответствует представленным в датасете данным для данного параметра.

Таким образом, можно сделать вывод о том, что существует строгая необходимость исключить признаки IC_{50} и CC_{50} при прогнозировании индекса селективности SI . Итоговая размерность подготовленного набора данных: 969 строк и 151 столбец.

Задачи регрессии

Для задач регрессии тестировались три алгоритма: Ridge Regression, Random Forest и XGBoost. Подбор гиперпараметров происходил при помощи метода GridSearchCV с 5-кратной кросс-валидацией. Для оценки использовались метрики R^2 на логарифмированном таргете и RMSE в исходной шкале.

- 1. Предсказание IC_{50}

Лучшей моделью оказался XGBoost ($R^2 = 0.4613$, RMSE = 382.4 mM), немного обогнавший Random Forest. Линейная модель Ridge ($R^2 = 0.3966$) справилась хуже, что доказывает наличие сложных нелинейных зависимостей между дескрипторами и эффективностью молекул.

- 2. Предсказание CC_{50}

Лучший результат показал XGBoost с метрикой $R^2 \approx 0.264$. Относительно невысокий процент объясненной дисперсии из-за сложности предсказания.

- 3. Предсказание SI

При строгом исключении IC_{50} и CC_{50} из признакового пространства для предотвращения data leakage, модель XGBoost достигла результата $R^2 = 0.219$. Учитывая комплексную физическую природу этого индекса, прямое предсказание SI «в лоб» является крайне сложной задачей, однако

ансамблевые алгоритмы смогли успешно выявить базовые нелинейные паттерны селективности в данной задаче.

Задачи классификации

Были протестированы Logistic Regression, Random Forest и XGBoost. Использовалось правильное разделение на train/test с последующим применением StandardScaler. Оценка производилась по метрикам ROC-AUC и F1-Score.

- 1. Классификация $IC_{50} > \text{Медианы}$

Наилучшую способность классификации в обеих задачах уверенно продемонстрировал Random Forest IC_{50} , с ROC-AUC = 0.8065, F1 = 0.7423.

- 2. Классификация $CC_{50} > \text{Медианы}$

Наилучшую способность классификации в обеих задачах уверенно продемонстрировал Random Forest CC_{50} , с ROC-AUC = 0.8354, F1 = 0.7474.

- 3. Классификация $SI > \text{Медианы}$

Прямое предсказание комплексного индекса оказалось сложнее. Лучшая модель Random Forest показала качество ROC-AUC = 0.6839, F1 = 0.5989. Бинарную границу селективности в пространстве 2D-дескрипторов достаточно сложно определить.

- 4. Поиск $SI > 8$

Наиболее эффективным алгоритмом вновь оказался Random Forest, достигнувший хорошего показателя ROC-AUC = 0.7430. Однако из-за дисбаланса классов наблюдается закономерное снижение F1-Score до 0.5736. Логистическая регрессия показала худшие результаты.

Выводы

В ходе работы доказана применимость алгоритмов машинного обучения для начального скрининга новых лекарственных препаратов. Ансамбли на основе решающих деревьев Random Forest и XGBoost стабильно превосходят линейные модели, успешно улавливая нелинейные зависимости химических параметров. Прогнозирование базовых параметров IC_{50} и CC_{50} математически дается алгоритмам легче, чем предсказание производного индекса SI. Для дальнейшего улучшения качества моделей рекомендуется добавить в датасет 3D-дескрипторы молекул для балансировки выборки в задаче $SI > 8$.